

Programación Para Mecatrónicos

Investigación

Codificación de caracteres y tipos de archivos

ASCII · UTF-8 · UTF-16 · JSON · XML · CSV

*Hecho por Diego Fabian Morales de Leon
2026-0256*

Parte 1: Codificación de caracteres

Las computadoras solo entienden números (ceros y unos). Entonces, para que puedan mostrar letras, tildes, emojis, etc, alguien tuvo que inventar un sistema que le asigne un número a cada caracter. A eso se le llama codificación de caracteres. Aquí investigué tres de las más usadas.

ASCII



ASCII fue una de las primeras codificaciones que se usaron. Nació en los años 60 y usa 7 bits, lo que le da 128 posibles combinaciones. Con eso alcanza para las letras del abecedario en mayúscula y minúscula, los números del 0 al 9 y algunos símbolos como el punto o el signo de pregunta.

Su gran problema es que no incluye tildes, ni la ñ, ni caracteres de otros idiomas (como el chino o el árabe). Por eso con el tiempo quedó corta.

Caracter	Codigo ASCII
A	65
a	97
0	48
espacio	32
!	33

UTF-8



UTF-8 es la codificación que más se usa hoy en día, sobre todo en internet. Lo interesante es que es compatible con ASCII: los primeros 128 caracteres son exactamente iguales. La diferencia es que UTF-8 puede usar de 1 a 4 bytes por carácter, así que puede representar prácticamente cualquier símbolo del mundo, incluyendo emojis.

Como ocupa menos espacio para el texto en inglés (usa 1 solo byte) es muy eficiente, y por eso casi todas las páginas web la usan por defecto.

```
Letra "A" -> 1 byte -> 01000001  
Letra "ñ" -> 2 bytes -> 11000011 10110001  
Emoji "😁" -> 4 bytes
```

UTF-16



UTF-16 usa bloques de 2 bytes (16 bits) como mínimo, y en algunos casos usa 4 bytes para caracteres poco comunes. A diferencia de UTF-8, no es compatible directamente con ASCII porque hasta la letra 'A' ocupa 2 bytes.


Se usa mucho por dentro de algunos programas y sistemas, por ejemplo Windows y Java lo usan internamente. Para texto en inglés ocupa más espacio que UTF-8, pero para idiomas como el chino o el japonés puede ser más eficiente.

```
Letra "A" -> 2 bytes -> 00000000 01000001  
Letra "字" -> 2 bytes
```

Parte 2: Tipos de archivos

Estos son formatos que se usan para guardar y compartir datos de forma ordenada, para que distintos programas los puedan leer sin problema. Investigué tres de los más comunes: JSON, XML y CSV.

JSON:



JSON significa JavaScript Object Notation. Es un formato liviano que organiza la información en pares de 'clave y valor', parecido a como funcionan los objetos en programación. Hoy en día es el formato más usado para que las páginas web y las apps se comuniquen con los servidores (APIs).

Su ventaja principal es que es fácil de leer para una persona y también fácil de procesar para una computadora.

```
{  
  "nombre": "Ana",  
  "edad": 21,  
  "curso": "Programación"  
}
```

XML



XML significa Extensible Markup Language. Guarda la información usando etiquetas, muy parecido a como se ve el HTML de una página web. Cada dato va dentro de una etiqueta de apertura y una de cierre.

Es más largo de escribir que JSON, pero se sigue usando mucho en configuraciones de programas, documentos de oficina (como los .docx) y algunos sistemas empresariales.

```
<persona>  
  <nombre>Ana</nombre>  
  <edad>21</edad>  
</persona>
```

CSV



CSV significa Comma Separated Values (valores separados por comas). Es el formato más simple de los tres: cada línea es una fila y cada dato va separado por una coma. Se usa mucho para tablas y hojas de cálculo, como Excel o Google Sheets.

No permite guardar estructuras complicadas (como JSON o XML), pero es súper liviano y casi cualquier programa lo puede abrir.

```
nombre,edad,curso  
Ana,21,Programación  
Luis,23,Diseño
```

Conclusión

En resumen, ASCII, UTF-8 y UTF-16 son formas de convertir letras en números para que la computadora las entienda, mientras que JSON, XML y CSV son formas de organizar esos datos ya convertidos, para guardarlos o enviarlos entre programas. Todos se complementan: un archivo JSON, por ejemplo, normalmente está codificado en UTF-8.